

TUGAS KELOMPOK

A. Mencari Dataset

Pada tahap pengumpulan data, kelompok kami mencari dataset yang relevan melalui platform dan menemukan dataset berjudul “Mercedes-Benz Sales Dataset 2020–2025”. Dataset ini berisi simulasi data penjualan mobil penumpang Mercedes-Benz secara global pada periode tahun 2020 hingga 2025. Dataset memiliki sekitar 12,1 juta baris data, di mana setiap baris merepresentasikan satu unit kendaraan yang terjual. Meskipun data yang digunakan bersifat sintetis, dataset dirancang menyerupai kondisi penjualan nyata dengan mempertimbangkan berbagai tren industri otomotif, seperti penurunan penjualan pada masa pandemi COVID-19 di tahun 2020, peningkatan penggunaan kendaraan hybrid dan listrik hingga tahun 2025, dominasi penjualan kendaraan SUV, serta ketahanan penjualan mobil mewah dan performa tinggi seperti S-Class, G-Class, dan AMG. Selain itu, dataset ini juga memuat informasi mengenai warna kendaraan, spesifikasi mesin, tenaga kuda, serta perubahan harga akibat inflasi secara bertahap. Dataset dipilih karena memiliki jumlah data yang besar, struktur yang rapi tanpa missing values, serta relevan untuk dianalisis dalam penelitian terkait penjualan dan tren industri otomotif.

B. Import Dataset

```
1 import kagglehub
2 import os
3 from pyspark.sql import SparkSession
4
5 # 1. Inisialisasi SparkSession
6 spark = SparkSession.builder \
7     .appName("LoadKaggleDataset") \
8     .getOrCreate()
9
10 # 2. Download dataset menggunakan kagglehub
11 # Fungsi ini akan mengembalikan path (lokasi folder) tempat dataset disimpan
12 dataset_dir = kagglehub.dataset_download("dhrubangtalukdar/mercedes-global-car-sales-2020-2025")
13
14 print(f"Dataset berhasil diunduh ke: {dataset_dir}")
15
16 # 3. Tentukan path file spesifik yang ingin dibaca
17 # Ganti "nama_file.csv" dengan nama file asli yang ada di dalam dataset tersebut
18
19 # Let's list the contents of the dataset directory to find the correct file name.
20 print(f"Contents of the dataset directory: {os.listdir(dataset_dir)}")
21
22 # Please replace "nama_file.csv" with the actual CSV file name from the list above.
23 file_name = "mercedes_benz_sales_2020_2025.csv" # <--- UPDATED THIS LINE WITH THE CORRECT FILE NAME
24 file_path = os.path.join(dataset_dir, file_name)
25
26 # 4. Load dataset ke PySpark DataFrame
27 # Asumsi file berupa CSV. Sesuaikan jika formatnya parquet/json.
28 df = spark.read.csv(
29     file_path,
30     header=True,      # Menggunakan baris pertama sebagai nama kolom
31     inferSchema=True  # Membiarkan Spark menebak tipe data secara otomatis
32 )
33
34 # 5. Tampilkan 5 data pertama
35 print("First 5 records:")
36 df.show(5)
```

Pada tahap persiapan data, dilakukan proses pengunduhan dan pemuatan dataset menggunakan library “kagglehub” serta PySpark. Pertama, sistem melakukan inisialisasi `SparkSession` sebagai lingkungan utama untuk pemrosesan data menggunakan framework Apache Spark. Setelah itu, dataset “Mercedes-Benz Sales Dataset 2020–2025” diunduh secara langsung dari platform Kaggle melalui fungsi `dataset\_download()`, kemudian lokasi penyimpanan dataset ditampilkan untuk memastikan proses unduhan berhasil dilakukan. Selanjutnya, file CSV yang terdapat di dalam folder dataset ditentukan dan dibaca menggunakan fungsi `spark.read.csv()`. Pada proses pembacaan data, parameter `header=True` digunakan agar baris pertama dikenali sebagai nama kolom, sedangkan `inferSchema=True` digunakan agar Spark dapat mendeteksi tipe data setiap kolom secara otomatis. Setelah dataset berhasil dimuat ke dalam PySpark DataFrame, dilakukan penampilan lima data pertama menggunakan fungsi `show(5)` untuk memastikan data telah terbaca dengan benar dan siap digunakan pada tahap analisis berikutnya.

C. Exploratory Data Analysis

1. Pemeriksaan Struktur Dataset

```
1 # 1. Display Schema to understand data types
2 print("DataFrame Schema:")
3 df.printSchema()
```

Pada tahap awal pengolahan data, dilakukan proses pemeriksaan struktur dataset menggunakan fungsi `printSchema()` pada PySpark. Proses ini bertujuan untuk memahami skema DataFrame, seperti nama kolom, tipe data, serta status nullable pada setiap atribut yang terdapat di dalam dataset. Dengan menampilkan schema, kelompok dapat memastikan bahwa data telah terbaca dengan benar dan memiliki tipe data yang sesuai sebelum dilakukan proses analisis lebih lanjut. Langkah ini penting karena kesalahan tipe data dapat memengaruhi proses pengolahan, perhitungan, maupun visualisasi data. Selain itu, pemeriksaan schema juga membantu dalam memahami karakteristik dataset sehingga proses eksplorasi dan analisis data dapat dilakukan secara lebih efektif dan terstruktur.

```

DataFrame Schema:
root
|-- Model: string (nullable = true)
|-- Year: integer (nullable = true)
|-- Region: string (nullable = true)
|-- Color: string (nullable = true)
|-- Fuel Type: string (nullable = true)
|-- Base Price (USD): integer (nullable = true)
|-- Horsepower: integer (nullable = true)
|-- Sales Volume: integer (nullable = true)
|-- Turbo: string (nullable = true)

```

Hasil pemeriksaan schema menunjukkan bahwa dataset penjualan Mercedes-Benz terdiri dari beberapa atribut dengan tipe data yang berbeda sesuai dengan karakteristik informasinya. Kolom seperti `Model`, `Region`, `Color`, `Fuel Type`, dan `Turbo` memiliki tipe data `string` karena berisi data kategorikal atau teks. Sementara itu, kolom `Year`, `Base Price (USD)`, `Horsepower`, dan `Sales Volume` bertipe `integer` karena berisi nilai numerik yang digunakan dalam proses perhitungan dan analisis data. Selain itu, seluruh kolom memiliki status `nullable = true`, yang menandakan bahwa setiap atribut memungkinkan memiliki nilai kosong. Pemeriksaan schema ini membantu memastikan bahwa struktur dataset telah sesuai dan siap digunakan untuk proses eksplorasi, analisis, maupun pengolahan data lebih lanjut menggunakan PySpark.

2. Melihat Ringkasan Informasi Dataset

```
df.describe().show()
```

summary	Model	Year	Region	Color	Fuel Type	Base Price (USD)	Horsepower	Sales Volume	Turbo
count	12132666	12132666	12132666	12132666	12132666	12132666	12132666	12132666	12132666
mean	NULL	2022.5475979475575	NULL	NULL	NULL	104216.92181190844	367.4593602098665	1.0	NULL
stddev	NULL	1.658896405304619	NULL	NULL	NULL	67833.88215800574	119.5446150589753	0.0	NULL
min	A-Class	2020	Global	Black	Diesel	35000	150	1	No
max	S-Class	2025	Global	Yellow	Petrol	411246	831	1	Yes

Hasil statistik deskriptif menggunakan fungsi `describe().show()` menunjukkan ringkasan informasi dari dataset penjualan Mercedes-Benz yang digunakan. Dataset memiliki total sekitar 12.132.666 data pada hampir seluruh kolom, yang menandakan jumlah data yang besar dan cukup representatif untuk proses analisis. Pada kolom numerik seperti `Year`, diperoleh nilai minimum

tahun 2020 dan maksimum tahun 2025, sesuai dengan periode data yang digunakan. Kolom 'Base Price (USD)' memiliki rata-rata harga kendaraan sekitar 104.216 USD dengan harga minimum 35.000 USD dan maksimum 411.246 USD. Sementara itu, kolom 'Horsepower' menunjukkan rata-rata tenaga kendaraan sekitar 367 HP dengan nilai minimum 150 HP dan maksimum 831 HP. Selain data numerik, statistik juga menampilkan nilai minimum dan maksimum pada data kategorikal, seperti model kendaraan dari 'A-Class' hingga 'S-Class', serta variasi warna kendaraan dari 'Black' hingga 'Yellow'. Hasil statistik deskriptif ini memberikan gambaran umum mengenai karakteristik data dan membantu dalam memahami distribusi nilai pada dataset sebelum dilakukan analisis lebih lanjut.

3. Melakukan Cek Missing Value

```
from pyspark.sql.functions import col, sum

print("Checking for null values per column:")
df.select([sum(col(c).isNull().cast("int")).alias(c) for c in df.columns]).show()

Checking for null values per column:
+-----+-----+-----+-----+-----+-----+-----+-----+
|Model|Year|Region|Color|Fuel Type|Base Price (USD)|Horsepower|Sales Volume|Turbo|
+-----+-----+-----+-----+-----+-----+-----+-----+
|  0  |  0  |  0  |  0  |  0  |  0  |  0  |  0  |  0  |
+-----+-----+-----+-----+-----+-----+-----+-----+

```

Berdasarkan hasil analisis *missing value* (nilai yang hilang) di setiap kolom DataFrame. Baris yang menampilkan angka '0' di bawah setiap nama kolom menunjukkan bahwa tidak ada nilai yang hilang atau kosong sama sekali di kolom-kolom tersebut. Yang menandakan data sudah dibersihkan dari sumber data (*Kaggle*)

4. Menghitung *Unique Value* Untuk Setiap Kategori

```
print("\nUnique values and counts for categorical columns:")
categorical_cols = ["Region", "Color", "Fuel Type", "Turbo", "Model", "Year"]
for col_name in categorical_cols:
    if col_name in df.columns:
        print(f"--- {col_name} ---")
        df.groupBy(col_name).count().show(truncate=False)
```

--- Region ---	
Region	count
Global	12132666
--- Color ---	
Color	count
Orange	121579
Silver	1819439
Green	364207
Blue	970358
White	2670085
Brown	242982
Yellow	363924
Black	3031663
Red	729300
Grey	1819129
--- Fuel Type ---	
Fuel Type	count
Diesel	2571699
Hybrid	2374855
Electric	1364746
Petrol	5821366

--- Turbo ---	
Turbo	count
No	1761369
Yes	10371297
--- Model ---	
Model	count
GLE	1546092
CLA	564731
C-Class	1504928
GLB	883773
AMG C 63	83158
GLC	2091045
AMG GT	65720
GLS	493201
A-Class	1618309
AMG A 45	103309
AMG E 63	53725
G-Class	217179
E-Class	1219554
CLS	138621
S-Class	374553
GLA	1129266
AMG S 63	45502

--- Year ---	
Year	count
2020	1776180
2021	2039570
2022	2000390
2023	2301289
2024	2111247
2025	1903990

Pada tahapan ini kami merancang skrip PySpark untuk mengotomatisasi analisis distribusi frekuensi pada kolom-kolom kategorikal. Proses diawali dengan menginisialisasi daftar atribut target yang diproses melalui perulangan (*looping*). Guna mencegah *error*, kami menerapkan validasi ``if col_name in df.columns`` untuk memastikan eksistensi kolom di dalam *DataFrame* sebelum program mengeksekusi fungsi utama ``df.groupBy().count()``. Kombinasi fungsi tersebut secara otomatis mengelompokkan data berdasarkan nilai unik dan menghitung total kemunculannya, yang hasilnya kemudian kami tampilkan secara utuh dan tanpa pemotongan teks menggunakan perintah ``show(truncate=False)``.

D. Spark SQL Analysis: Averages, Trends, and Insights

1. Harga Dasar Rata-rata dan Horsepower per Model per Tahun

```
df.createOrReplaceTempView("mercedes_sales")
```

```

avg_metrics_query = """
SELECT
    Model,
    Year,
    AVG(`Base Price (USD)`) AS average_base_price,
    AVG(Horsepower) AS average_horsepower
FROM
    mercedes_sales
GROUP BY
    Model, Year
ORDER BY
    Model, Year
"""

avg_metrics_df = spark.sql(avg_metrics_query)
print("\nAverage Base Price and Horsepower per Model per Year:")
avg_metrics_df.show()

```

```

Average Base Price and Horsepower per Model per Year:
+-----+-----+-----+-----+
|  Model|Year|average_base_price|average_horsepower|
+-----+-----+-----+-----+
| A-Class|2020| 62542.16783172182| 285.7734477978757|
| A-Class|2021|64672.998959125194|285.49701187065085|
| A-Class|2022| 66877.78850450944| 285.3804582290864|
| A-Class|2023| 69075.30737350842| 285.4792605132031|
| A-Class|2024| 71253.45484356713|285.42218677742574|
| A-Class|2025| 73466.08230787184| 285.5942150290134|
|AMG A 45|2020|235374.93244112725| 405.5025093295586|
|AMG A 45|2021| 243464.8127212949|405.53256196256956|
|AMG A 45|2022|251228.59735879258|405.51720786645325|
|AMG A 45|2023|260901.42808290155| 405.4873575129534|
|AMG A 45|2024| 268079.6206934568| 405.4196020065046|
|AMG A 45|2025|276157.29075096955| 405.5320836761077|
|AMG C 63|2020|235042.60848134613| 493.2707572023455|
|AMG C 63|2021| 242365.0554907744|493.05699979422457|
|AMG C 63|2022|251650.49442612656|493.08651279635734|
|AMG C 63|2023|260361.37647058823| 493.0704589528119|
|AMG C 63|2024| 268502.7098987259|492.94158771643254|
|AMG C 63|2025| 276307.8210391759|493.08060756447856|
|AMG E 63|2020|235227.91930207197| 591.8721676965952|
|AMG E 63|2021| 243680.7216652907| 591.5274206864017|
+-----+-----+-----+-----+
only showing top 20 rows

```

Tabel 'Average Base Price and Horsepower per Model per Year' ini memberikan gambaran tentang bagaimana rata-rata harga dasar dan horsepower untuk setiap model Mercedes-Benz berkembang dari tahun ke tahun. Anda bisa mengamati tren kenaikan atau penurunan harga, serta perubahan dalam performa

mesin (horsepower) untuk model-model tertentu. Misalnya, beberapa model mungkin menunjukkan peningkatan harga setiap tahun, yang bisa jadi karena pembaruan model atau inflasi, sementara horsepower relatif stabil atau menunjukkan peningkatan bertahap.

2. Trend Penjualan Selama Setahun


```
sales_trend_query = """
SELECT
    Year,
    SUM(`Sales Volume`) AS total_sales_volume,
    AVG(`Base Price (USD)`) AS avg_price_per_year
FROM
    mercedes_sales
GROUP BY
    Year
ORDER BY
    Year
"""

sales_trend_df = spark.sql(sales_trend_query)
print("\nSales Trend Over the Years:")
sales_trend_df.show()

# Convert to Pandas for plotting
sales_trend_pandas = sales_trend_df.toPandas()

plt.figure(figsize=(10, 6))
sns.lineplot(x='Year', y='total_sales_volume', data=sales_trend_pandas)
plt.title('Total Sales Volume Over Years')
plt.xlabel('Year')
plt.ylabel('Total Sales Volume')
plt.xticks(sales_trend_pandas['Year'])
plt.grid(True)
plt.show()
```

```
Sales Trend Over the Years:
+---+-----+-----+
|Year|total_sales_volume|avg_price_per_year|
+---+-----+-----+
|2020|          1776180| 95488.06884381088|
|2021|          2039570| 99805.11602396583|
|2022|          2000390|101114.52819300236|
|2023|          2301289|105559.46463351625|
|2024|          2111247|108660.50274174457|
|2025|          1903990|113795.29251361614|
+---+-----+-----+
```



Volume Penjualan Total: Kita dapat mengamati bagaimana total volume penjualan kendaraan Mercedes-Benz berubah dari tahun 2020 hingga 2025. Terlihat adanya peningkatan penjualan dari tahun 2020 ke 2021, sedikit penurunan di 2022, lonjakan signifikan di 2023, kemudian sedikit penurunan di 2024 dan 2025. Puncak penjualan terjadi di tahun 2023.

Harga Rata-rata per Tahun: Rata-rata harga dasar kendaraan menunjukkan tren kenaikan yang konsisten setiap tahunnya, dari sekitar \$95,488 di tahun 2020 menjadi sekitar \$113,795 di tahun 2025. Ini mungkin mencerminkan inflasi, pembaruan model dengan fitur-fitur yang lebih canggih, atau strategi penetapan harga premium oleh Mercedes-Benz.

3. Mencari Trend Penjualan per Tahun Berdasarkan Volume Fuel

Dalam tahapan analisis lanjutan, kami mengimplementasikan kueri SQL melalui antarmuka PySpark untuk mengevaluasi distribusi penjualan kendaraan berdasarkan tipe bahan bakar di setiap tahunnya. Kueri tersebut dirancang untuk mengekstrak atribut 'Year' dan 'Fuel Type' dari tabel referensi 'mercedes_sales', serta menerapkan fungsi agregasi 'SUM()' pada kolom 'Sales Volume' guna mengalkulasi total unit yang terjual. Selanjutnya, data tersebut dikelompokkan menggunakan klausa 'GROUP BY' dan diurutkan secara menurun ('DESC')

menggunakan `ORDER BY` berdasarkan total volume penjualan tertinggi, sehingga tren preferensi bahan bakar terlaris pada masing-masing tahun dapat teridentifikasi dengan jelas. Kueri ini kemudian dieksekusi menjadi sebuah DataFrame baru melalui metode `spark.sql()` dan hasil laporannya ditampilkan dalam format tabel menggunakan fungsi `show()`.

```
fuel_type_sales_query = """
SELECT
    Year,
    `Fuel Type`,
    SUM(`Sales Volume`) AS total_sales_volume_fuel_type
FROM
    mercedes_sales
GROUP BY
    Year, `Fuel Type`
ORDER BY
    Year, total_sales_volume_fuel_type DESC
"""

fuel_type_sales_df = spark.sql(fuel_type_sales_query)
print("\nSales Distribution by Fuel Type per Year:")
fuel_type_sales_df.show(25)
```

Sales Distribution by Fuel Type per Year:		
Year	Fuel Type	total_sales_volume_fuel_type
2020	Petrol	1207121
2020	Diesel	533532
2020	Hybrid	35527
2021	Petrol	1264082
2021	Diesel	571019
2021	Hybrid	163441
2021	Electric	41028
2022	Petrol	1100103
2022	Diesel	499818
2022	Hybrid	300071
2022	Electric	100398
2023	Petrol	1035812
2023	Hybrid	575247
2023	Diesel	459401
2023	Electric	230829
2024	Petrol	738922
2024	Hybrid	633938
2024	Electric	421339
2024	Diesel	317048
2025	Hybrid	666631
2025	Electric	571152
2025	Petrol	475326
2025	Diesel	190881

Gambar menampilkan tabel "Sales Distribution by Fuel Type per Year" yang memuat hasil agregasi volume penjualan kendaraan berdasarkan tipe bahan bakar dari tahun 2020 hingga 2025. Melalui laporan keluaran tersebut, kami mengidentifikasi adanya pergeseran tren pasar yang signifikan dari penggunaan bahan bakar konvensional menuju energi alternatif. Pada periode 2020 hingga 2022, penjualan didominasi secara absolut oleh kendaraan berbahan bakar bensin (Petrol) dan diesel (Diesel). Namun, seiring berjalannya waktu, kendaraan ramah lingkungan menunjukkan lonjakan adopsi yang pesat; dimulai dari kemunculan perdana kendaraan listrik (Electric) di tahun 2021, hingga keberhasilan kendaraan Hybrid menyalip volume penjualan Diesel pada tahun 2023. Transisi ini mencapai puncaknya pada tahun 2025, di mana kendaraan Hybrid dan Electric berhasil mengambil alih puncak penjualan tertinggi (masing-masing menyentuh 666.631 dan 571.152 unit), sementara angka penjualan Petrol dan Diesel mengalami penurunan drastis hingga menempati urutan terbawah.

4. Mencari Tipe Model Mobil Dengan Rata-rata Base Price Tertinggi

```
top_price_models_query = """
SELECT
    Model,
    AVG(`Base Price (USD)`) AS average_base_price
FROM
    mercedes_sales
GROUP BY
    Model
ORDER BY
    average_base_price DESC
LIMIT 5
"""

top_price_models_df = spark.sql(top_price_models_query)
print("\nTop 5 Models with Highest Average Base Price:")
top_price_models_df.show()
```

Pada tahapan ini kami melakukan implementasi kueri SQL untuk mengidentifikasi lima model kendaraan premium dengan rata-rata harga dasar tertinggi di dalam dataset. Prosesnya diawali dengan menyeleksi kolom Model dan menghitung nilai rata-rata dari Base Price (USD) menggunakan fungsi agregasi AVG() pada tabel rujukan mercedes_sales. Data tersebut kemudian

dikelompokkan menggunakan klausa GROUP BY, diurutkan secara menurun (DESC) berdasarkan kalkulasi harga rata-rata, dan dibatasi hasilnya menggunakan klausa LIMIT 5 untuk mendeduksi peringkat lima teratas. Kueri tersebut selanjutnya dieksekusi menjadi sebuah DataFrame baru melalui metode spark.sql() dan laporan akhirnya dicetak ke layar menggunakan fungsi show()

```
Top 5 Models with Highest Average Base Price:
+-----+-----+
|  Model|average_base_price|
+-----+-----+
|AMG A 45| 256527.5245912747|
|  AMG GT|256511.70252586732|
|AMG S 63|256432.15478440508|
|  G-Class|256373.28241680824|
|AMG C 63|256337.96744750955|
+-----+-----+
```

Berdasarkan tabel tersebut, terlihat bahwa jajaran mobil premium di dalam dataset didominasi secara kuat oleh seri performa tinggi (AMG). Model AMG A 45 menempati urutan pertama dengan rata-rata harga dasar mencapai sekitar \$256.527. Posisi tersebut kemudian disusul secara berturut-turut dengan selisih harga yang sangat tipis oleh model AMG GT (\$256.511), AMG S 63 (\$256.432), dan G-Class (\$256.373). Daftar lima teratas ini ditutup oleh model AMG C 63 di posisi kelima dengan rata-rata harga sekitar \$256.337, yang secara keseluruhan memvalidasi segmentasi harga eksklusif untuk lini kendaraan unggulan tersebut.

5. Rata-rata Horsepower untuk Kendaraan Turbo vs. Non-Turbo

```
turbo_horsepower_query = """
SELECT
    Turbo,
    AVG(Horsepower) AS average_horsepower
FROM
    mercedes_sales
GROUP BY
    Turbo
ORDER BY
    Turbo
"""

turbo_horsepower_df = spark.sql(turbo_horsepower_query)
print("\nAverage Horsepower for Turbo vs. Non-Turbo Vehicles:")
turbo_horsepower_df.show()
```

```

Average Horsepower for Turbo vs. Non-Turbo Vehicles:
+-----+-----+
| Turbo | average_horsepower |
+-----+-----+
|   No  | 362.05307065129455 |
|   Yes | 368.37751642827317 |
+-----+-----+

```

Output ini membandingkan rata-rata horsepower antara kendaraan yang dilengkapi dengan turbocharger ('Yes') dan yang tidak ('No'). Hasil menunjukkan bahwa kendaraan dengan turbo memiliki rata-rata horsepower sekitar 368.38, yang sedikit lebih tinggi dibandingkan kendaraan non-turbo yang rata-rata horsepower-nya sekitar 362.05. Wawasan ini mengkuantifikasi perbedaan performa yang diharapkan, menegaskan bahwa kendaraan dengan turbocharger umumnya memiliki horsepower yang lebih besar dalam dataset ini.

6. Ringkasan

Berdasarkan serangkaian eksplorasi dan analisis data menggunakan PySpark, dapat disimpulkan bahwa dataset penjualan kendaraan berskala besar ini terverifikasi sangat bersih dan terbebas dari anomali data yang hilang. Analisis lebih lanjut mengungkap adanya pergeseran tren preferensi pasar yang signifikan dari tahun 2020 hingga 2025, di mana dominasi kendaraan berbahan bakar konvensional secara bertahap berhasil digeser oleh opsi yang lebih ramah lingkungan seperti Hybrid dan Electric. Di samping itu, hasil evaluasi pada spesifikasi dan harga mengonfirmasi bahwa segmen pasar premium secara eksklusif didominasi oleh lini performa tinggi dan SUV mewah (seperti seri AMG dan G-Class), sementara analisis komponen mesin membuktikan bahwa integrasi teknologi turbocharger secara konsisten memberikan peningkatan tenaga (horsepower) yang lebih superior dibandingkan model non-turbo.